

PSet #1 — Propuesta y Diseño del Proyecto

Grupo: Isabella Tulcán, Gabriel Ávalos, Keoma Quiroga, David Bucheli, James Soto

Nota de alcance. Esta propuesta usa datos históricos públicos de M5 como caso de estudio. El MVP demostrará pronóstico de ventas y una simulación de reposición, no afirma operar ni conocer los procesos internos de Walmart.

1. Tres oportunidades de proyecto

Idea 1 — Pronóstico de ventas y simulación de reposición minorista

Problema de negocio. Un minorista debe anticipar las ventas por producto y tienda para planificar la reposición. Los errores de planificación pueden provocar faltantes o exceso de inventario, afectando al área de abastecimiento, a las tiendas y a sus clientes.

Predicción. Unidades vendidas diariamente por cada combinación SKU–tienda durante los siguientes 28 días.

Datos. Se utilizará el dataset público de la competencia [M5 Forecasting Accuracy de Kaggle](#), condicionado a registro y aceptación de sus reglas. Incluye ventas históricas diarias por producto y tienda, calendario, eventos, SNAP y precios. La guía de M5 documenta 3.049 productos, 10 tiendas y tres estados de EE. UU. [Guía de participantes M5](#).

Acción. Cada semana, el sistema producirá una recomendación simulada de cobertura por SKU–tienda. Un responsable revisaría la salida antes de cualquier decisión operativa.

Riesgo principal. El dataset no incluye inventario disponible, órdenes en tránsito, lead time, costo de mantener inventario ni ventas perdidas, por ello, permite evaluar pronóstico, pero no validar una orden real de compra.

Idea 2 — Recomendación personalizada de películas

Problema de negocio. Una plataforma de streaming quiere reducir el esfuerzo que hace un usuario para encontrar contenido relevante y aumentar el uso de su catálogo.

Predicción. Rating o preferencia esperada de un usuario por una película que aún no ha calificado.

Datos. Se utilizará [MovieLens 32M](#), publicado por GroupLens Research de la Universidad de Minnesota. Contiene 32 millones de ratings, 200.948 usuarios y 87.585 películas; incluye ratings, películas, tags y enlaces. Se revisarán sus términos de uso antes de descargarlo.

Acción. Mostrar un Top 10 de películas no calificadas, ordenadas por preferencia estimada.

Riesgo principal. MovieLens no contiene reproducciones, cancelaciones ni ingresos de una plataforma comercial. Por tanto, es posible evaluar el ranking offline, pero no demostrar directamente reducción de churn.

Idea 3 — Clasificación de riesgo de bancarrota empresarial

Problema de negocio. Un fondo o un área de crédito necesita priorizar la revisión de empresas con mayor riesgo de insolvencia, antes de asignar recursos a una evaluación detallada.

Predicción. Probabilidad de bancarrota de una empresa dentro del horizonte definido por el dataset.

Datos. Se utilizará [Polish Companies Bankruptcy Data](#), publicado en el repositorio UCI. Incluye 7.027 estados financieros, 64 ratios financieros y una etiqueta de bancarrota. La fuente reporta 271 empresas quebradas y 6.756 no quebradas.

Acción. Priorizar due diligence o revisión financiera adicional; el modelo no aprobará ni rechazará inversiones automáticamente.

Riesgo principal. Los datos no representan específicamente startups o empresas de IA actuales y el target está desbalanceado, por lo que la generalización a una cartera real es limitada.

2. Comparación y selección

Criterio	Idea 1: ventas M5	Idea 2: MovieLens	Idea 3: bancarrota UCI
Valor de negocio	Alto	Alto	Alto
Acceso a datos	Alto, sujeto a reglas Kaggle	Alto	Alto
Target observable	Alto	Alto	Alto
Acción	Medio	Alto	Alto
Evaluación	Alto	Alto	Alto
Alcance	Medio/Alto, con piloto	Alto	Medio
Decisión	Seleccionada	Alternativa viable	Alternativa viable

Se selecciona la Idea 1 porque combina un problema empresarial concreto, una fuente pública con ventas temporales, señales de calendario y precio, un target observable y una evaluación temporal objetiva. El alcance será un piloto de pronóstico y simulación, no un sistema de inventario real.

3. Propuesta del proyecto seleccionado

3.1 Problema de negocio y formulación de ciencia de datos

Un minorista necesita estimar sus ventas futuras para planificar reposición antes de que ocurra la demanda. Sobreestimar aumenta la cobertura simulada de inventario; subestimar eleva el riesgo de faltantes. El MVP mejorará un baseline de pronóstico y traducirá sus resultados en una recomendación simulada.

Elemento	Definición
Unidad de predicción	SKU–tienda–día.
Target	Unidades vendidas observadas por SKU y tienda cada día. Se habla de ventas observadas, no de demanda latente.
Horizonte	28 días exactos. M5 fue diseñado para pronósticos de cuatro semanas.
Métrica técnica principal	WAPE, calculado por SKU–tienda y para el conjunto piloto.
Métrica técnica secundaria	RMSSE, para mantener coherencia con la evaluación de M5.

Elemento	Definición
Baseline	Promedio móvil de los últimos 30 días, calculado únicamente con observaciones disponibles antes de cada corte temporal.
Umbral de decisión	Se genera alerta cuando el pronóstico acumulado de 28 días supera la cobertura de inventario simulada.
Métrica de negocio del MVP	Reducción simulada de unidades faltantes y de inventario excedente frente al baseline.

La calidad técnica se medirá con WAPE y RMSSE. El valor de negocio se evaluará en una simulación con parámetros explícitos. Los resultados no se presentarán como ahorro real porque M5 no provee inventario, costos ni ventas perdidas.

3.2 Viabilidad técnica y de datos

Fuente	Acceso	Contenido	Cobertura y restricciones
sales_train_validation.csv	Público, sujeto a reglas de Kaggle	Ventas diarias por producto y tienda; d_1 a d_1913.	No contiene inventario ni órdenes.
sales_train_evaluation.csv	Público, sujeto a reglas de Kaggle	Extiende las ventas hasta d_1941.	Debe separarse cronológicamente para evitar fuga de información.
calendar.csv	Público, sujeto a reglas de Kaggle	Fecha, semana, eventos, SNAP, día de semana, mes y año.	No contiene detalle de campañas comerciales.
sell_prices.csv	Público, sujeto a reglas de Kaggle	Precio por SKU–tienda–semana.	El precio es semanal promedio; no existe una columna explícita de promociones.

La historia máxima cubre 1.941 días, desde 2011-01-29 hasta 2016-06-19. Las ventas se observan diariamente, mientras que los precios son semanales. El dataset es histórico y estático: no incorpora un flujo operativo en tiempo real.

3.3 Viabilidad de negocio

El flujo de trabajo esperado es:

Ventas históricas → pronóstico de 28 días → simulación de cobertura → recomendación → revisión humana → comparación contra baseline.

En el MVP, la acción será revisada por una persona responsable antes de actuar. Para escalar el proyecto se requerirían datos operativos adicionales: inventario disponible, inventario en tránsito, lead time, mínimo de pedido, costos de compra, costos de almacenamiento y costo de faltante.

La métrica de negocio compara la política simulada basada en el modelo con la política simulada basada en el baseline. Una reducción de faltantes simulados y de exceso simulado, manteniendo los mismos supuestos, sería evidencia de mejora frente al proceso base.

3.4 Riesgos

Tipo	Supuesto en riesgo	Cómo se verificará	Severidad	Respuesta
Técnico	Las ventas futuras mantienen patrones aprendibles.	Backtesting con varios cortes de 28 días.	Alta	Reentrenar y monitorear WAPE/RMSSE por SKU.
Técnico	Las series intermitentes se pueden estimar con suficiente precisión.	Medir error separado para SKUs con muchos días en cero.	Media	Segmentar series o agregar por categoría.
Negocio	El pronóstico permite simular una decisión útil.	Revisar disponibilidad de inventario, lead time y costos.	Alta	Limitar el MVP a pronóstico si faltan esos datos.
Negocio	Las personas usuarias aceptarán las recomendaciones.	Medir tasa de aprobación y modificaciones en una prueba futura.	Media	Explicar la recomendación y mantener aprobación humana.

3.5 Alcance del semestre

Producto mínimo viable. Un pipeline reproducible que integra los archivos M5, transforma las series al formato de análisis, construye variables de calendario y precio, entrena un modelo, compara con un baseline en backtesting de 28 días y genera un archivo o dashboard local de pronósticos y recomendaciones simuladas.

Despliegue mínimo. Ejecución local o programada que produce semanalmente el archivo de predicciones por SKU-tienda.

Monitoreo. Tablero o reporte con WAPE/RMSSE por corte temporal, porcentaje de SKUs con error mayor a un umbral y comparación continua contra el baseline.

Fuera de alcance. Integración con sistemas de Walmart, emisión automática de órdenes de compra, datos en tiempo real, prueba A/B operativa, cálculo de ahorro real e infraestructura de nube empresarial.

Fuentes

- [M5 Forecasting Accuracy — Kaggle](#)
- [M5 Participants Guide](#)
- [MovieLens datasets — GroupLens](#)
- [Polish Companies Bankruptcy Data — UCI](#)